

## נפרט על כל חלק בנפרד

### • חלק 1:

בקטע קוד זה, התבקשנו למצוא את המחיר האופטימלי אותו הלקוחות מוכנים לשלם (ערך  $v_t$  עבור מוצר מסוים, כאשר ערך זה אינו ידוע מראש ומשתנה באופן רנדומלי עבור כל לקוח. לצורך כך, המשתמשת באלגוריתם של חיפוש בינארי כדי למצוא את הערך האופטימלי שהלקוחות מוכנים לשלם, מתוך הנחה שערך זה קבוע לאורך זמן. דרך החשיבה מאחורי פתרון זה היא שברגע שנמצא את המחיר הנכון במהירות, נוכל להציע את אותו מחיר בכל אינטראקציה ולהשיג את הרווח המקסימלי. האלגוריתם מתחיל מהגדרה של גבולות עליון ותחתון (בין 0 ל-1) ומחשב את המחיר הנוכחי כהממוצע שלהם. בכל אינטראקציה עם הלקוח, המחיר מותאם על בסיס האם הלקוח קנה את המוצר או לא: אם הלקוח קנה, המחיר המוצע נחשב כנמוך מדי ולכן הגבול התחתון מתעדכן למעלה, ולהיפך אם הלקוח לא קנה. כדי להוסיף דיוק בתהליך החיפוש, נוסף רעש קטן למחיר הנוכחי לפני עדכון הגבולות, מה שמאפשר להגיע למחיר מדויק יותר מהר יותר. כל זאת כדי למקסם את הרווח לאורך כל האינטראקציות.

### • חלק 2:

בקטע הקוד הנוכחי, נדרשנו למצוא את המחיר האופטימלי עבור מוצר על בסיס התפלגות בטא עם פרמטרים  $alpha$  ו- $beta$  ידועים. לצורך כך, חישבנו את ההכנסה הצפויה עבור מגוון מחירים אפשריים. הגיוני להשתמש בגישה זו מכיוון שהתפלגות בטא מאפשרת לנו להעריך את ההסתברות שהלקוחות יהיו מוכנים לשלם מחיר מסוים. על בסיס זה, ביצענו סימולציה שבדקת כל מחיר אפשרי בטווח של 0 עד 1, בחלוקה ל-1000 מחירים, וחישבנו את ההכנסה הצפויה עבור כל אחד מהם. לבסוף, בחרנו את המחיר שמביא להכנסה הצפויה הגבוהה ביותר, והתוצאה היא המחיר האופטימלי אותו נציע ללקוחות לאורך כל האינטראקציה. גישה זו מבוססת על הידע המוקדם שיש לנו לגבי ההתפלגות של הערכים שהלקוחות מוכנים לשלם, ומבטיחה שנבחר במחיר שממקסם את ההכנסות שלנו על פני כל הלקוחות.

### • חלק 3:

בקטע הקוד הנוכחי, נדרשנו למצוא את המחיר האופטימלי שהלקוחות יהיו מוכנים לשלם עבור מוצר מסוים כאשר הפרמטרים של ההתפלגות אינם ידועים מראש. כדי להתמודד עם בעיה זו, יישמנו את הגישה שהוצגה בתרגול 7, שבה השתמשנו בשיטות בייסיאניות וב-Thompson Sampling. התחלנו עם פרמטרים ראשוניים של התפלגות בטא  $alpha = 1$ ,  $beta = 1$ , בהתאם לתגובות הלקוחות (האם הם קונים את המוצר או לא), עדכנו את הפרמטרים של ההתפלגות באמצעות תהליך בייסיאני, שבו כל הקלקה מעדכנת את מספר ה-Clicks ומביאה להתפלגות בטא חדשה. כאשר לקוח רכש את המוצר, ערך  $alpha$  גדל ב- $q$ , מה שמחזק את ההערכה שהמחיר המוצע היה נכון. לעומת זאת, אם הלקוח לא רכש את המוצר, ערך  $beta$  גדל ב- $g$ , מה שמקטין את ההסתברות למחירים גבוהים יותר בהתפלגות שלנו. בכל שלב, המחיר המוצע מחושב על בסיס ממוצע ההתפלגות המשוערת יחד עם מרווח ביטחון, המאפשר חישוב מותאם לדינמיות של מספר הסיבובים שכבר עברו, על ידי שימוש בפונקציה לוגריתמית. גישה דינמית זו מבטיחה שהמחיר המוצע יתאים את עצמו באופן אוטומטי להתנהגות הלקוחות בזמן אמת, תוך שמירה על דיוק ותגובה לשינויים לאורך זמן, ובכך משפרת את היכולת למקסם רווחים לאורך תקופת הסימולציה.